

UNIwersytet Gdański
Wydział Matematyki, Fizyki i Informatyki

Paweł Luszuk

nr albumu: 235425

Transfer Stylu przy użyciu Uczenia Maszynowego w Blenderze

Praca magisterska na kierunku:

INFORMATYKA

Promotor:

dr P. Arłukowicz

Gdańsk 2020

Streszczenie

Implementacja algorytmu Neural-Style opracowanego przez Leona A. Gatysa, Alexandra S. Eckera i Matthiasa Bethge w środowisku Blender.

Neural-Style lub Neural-Transfer pozwala robić zdjęcia i odtwarzać je w nowym stylu artystycznym.

Słowa kluczowe

Blender, Python, PyTorch, Machine Learning

Spis treści

Wprowadzenie	6
1. Wprowadzenie do sztucznej inteligencji	7
1.1. Uczenie maszynowe	7
1.2. Głębokie uczenie	7
2. Konwolucyjne Sieci Neuronowe	9
3. Widzenie komputerowe	14
4. Transfer Stylu	17
5. Przegląd dostępnych narzędzi	19
5.1. Blender	19
5.2. Python	19
5.3. Wtyczki	19
5.4. PyCharm	20
5.5. Jupyter Notebook	20
5.6. CUDA	20
6. Przegląd dostępnych bibliotek	21
6.1. PIP	21
6.2. BPY	21
6.3. PyTorch	21
6.4. NumPy	24
6.5. Torchvision	25
6.6. Pillow	25
6.7. OS	26
7. Źródła	27

wersja wstępna [2020.5.12] 5

Zakończenie 28

A. Tytuł załącznika jeden 29

B. Tytuł załącznika dwa 30

Oświadczenie 31

Wprowadzenie

Żyjemy w czasach niespotykanego nigdy w historii ludzkości tempa rozwoju nauki i technologii. Komputery są obecnie w stanie wykonywać zadania, które jeszcze 20 lat temu mogły pojawić się tylko w książkach Philipa K. Dicka czy Wiliama Gibsona.

Zadania, które jeszcze kilka lat temu wymagały wyższego poznania, są rozwiązywane przez maszyny o niemal nadludzkim poziomie wydajności. Zawody, bez których ludzkość dziesięciolecia temu nie mogła się obejść nie istnieją. Do zadań takich jak wykrywanie znaków drogowych i pieszych przez autonomiczne samochody czy diagnozowanie guza na podstawie obrazu radiologicznego można teraz podejść komputerowo. Analiza obrazu czy obróbka dźwięku może odciążyć człowieka w prostych powtarzalnych czynnościach.

ROZDZIAŁ 1

Wprowadzenie do sztucznej inteligencji

Sztuczna inteligencja to najbardziej ogólne pojęcie związane z komputerami. Prostą sztuczną inteligencję reprezentuje nawet kalkulator. Przyjeto też, iż wyznacznikiem jakości sztucznej inteligencji jest umiejętność „udawania” ludzkiego mózgu. Już w roku 1950 Alan Turing opracował test, test określający w jakim stopniu maszyna jest w stanie myśleć jak człowiek.

1.1. Uczenie maszynowe


To dziedzina nauki łącząca ze sobą informatykę, matematykę czy statystykę. Kładzie ona szczególny nacisk na analizę danych i zmianę postępowanie w zależności od otrzymanych informacji.

1.2. Głębokie uczenie

Głębokie uczenie jest podkategorią uczenia maszynowego. Polega na znajdowaniu powiązań między elementami w zbiorze danych niedostrzegalnym przez człowieka. Zajmuje się głównie przetwarzaniem dźwięku np. rozpoznawanie głosu. Przetwarzaniem języka naturalnego np. tłumaczenia czy analizę obrazu np. identyfikowanie osób.

W tej pracy uwaga zostanie poświęcona tylko analizie obrazu, natomiast wiele mechanizmów pracy z dużą ilością danych pozostaje identyczna, gdyż dane takie jak obraz czy plik audio są tylko zestawem danych liczbowych np. obraz w formacie cyfrowym jest to zbiór pikseli o 3 wartościach liczbowych a plik audio to tablica liczb przechowująca amplitudy dźwięku w danym czasie.

Głębokie uczenie to transformacje danych wejściowych, których wynikiem są funkcje numeryczne, które ułatwiają algorytmowi niższego rzędu, takim jak klasyfikator, uzyskanie poprawnych wyników na nowych danych. Głębokie uczenie ma na celu pobranie oryginalnych danych i przedstawienie reprezentacji tych samych danych, które można podać algorytmowi w celu rozwiązania problemu. Głębokiego uczenia się można użyć w przypadku modeli ogólnych, które nie są zaprojektowane do rozwiązania określonego zadania, ale mogą być automatycznie dostosowywane do specjalizacji w problemie.



Rysunek 1.1. Schemat zależności

Źródło: Opracowanie własne

ROZDZIAŁ 2

Konwolucyjne Sieci Neuronowe

Sieci neuronowe to ogólna nazwa struktur matematycznych wzorowane są na neuronach w mózgu. Sieci neuronowe mogą być automatycznie dostosowywane, aby specjalizować się w danym problemie.

W tej pracy uwaga poświęcona będzie tylko Konwolucyjnym sieciom neuronowym (ang. Convolutional Neural Network), które sprawdzają się przy analizie obrazów. Warto jednak wspomnieć o innych np. Long short-term memory network, które swoje zastosowanie ma w analizie dźwięku. Konwolucyjna sieć neuronowa składa się z jednej lub wielu warstw klastrów połączeń.


Posłużmy się przykładem prostej sieci neuronowej, która ma za zadanie rozpoznać pisane cyfry. Jest to swego rodzaju "Hello, World!" w dziedzinie uczenia maszynowego. W przypadku analizy obrazka 64x64 piksele jedna warstwa sieci neuronowej sieć neuronowa składać będzie się z 4096 neuronów.

Neuronem określamy najbardziej elementarną część modelu uczenia maszynowego, często jest to pojedyncza liczba np. odcień szarości (ang. Gray-scale Value) dla pojedynczego piksela w przypadku czarno-białego obrazka. Neuron jest podstawowym budulcem sieci neuronowej. Neurony są ze sobą połączone w dużej liczbie, tworząc sieć.

Ostatnią warstwą jest output cyfr 0 - 10 i ta z największą wartością aktywacji zostaje wybrana.

Dokładniej mówiąc neuron to funkcja, która przyjmuje dane wejściowe ze wszystkich neuronów z poprzedniej warstwy i przetwarza to na wartość od 0 do 1, 0 to czarny 1 to biały wartość ta zwana jest "aktywacją" lub "funkcją aktywacji". Aktywacja z poprzedniej warstwy, determinuje aktywację w kolejnych aż do samego końca.

Funkcja aktywacji Najprostszą jednostką w (głębokich) sieciach neuronowych jest operacja liniowa (skalowanie + przesuwanie), po której następuje funkcja aktywacji. W swoim najnowszym modelu miałeś operację liniową;



Rysunek 2.1. Układ neuronów dla obrazka 64x64 px

Źródło: Opracowanie własne

operacja liniowa była całym modelem. Funkcja aktywacji ma na celu skoncentrowanie wyników poprzedniej operacji liniowej w danym zakresie.


Dla każdego neuronu wykonywana jest operacja matematyczna:

$$\text{neuron} = (w * x + b)$$

Zmienna “x” jest wkładem do obliczeń pojedynczego neuronu, w przypadku rozpoznawania cyfr x jest wartością 0 - 1 odcieniem szarości dla danego piksela, “w” jest wagą, natomiast b to odchylenie.

Waga jest to wartość, która na swój sposób określa “ważność” danych neuronów w przypadku rozpoznawania cyfr pisanych piksele na skraju obrazka będą miały mniejsze znaczenie niż te w okolicach jego centrum. Wagi

mówią ci, jaki wzór pikselowy odbiera ten neuron w drugiej warstwie. Wagi mnożymy z aktywacją, aby wagi pomagały w określeniu stopnia aktywacji, zachowujemy je w przedziale 0-1 tu okazuje się pomocna funkcja aktywacji.




Rysunek 2.2. Przypisywanie wag

Źródło: Opracowanie własne

Dodawane jeszcze jest odchylenie (bias), który mówi ci, jak wysoka musi być suma ważona, zanim neuron zacznie być znacząco aktywny.

W każdej warstwie wartość w neuronie po dodaniu odchylenia i przemnożeniu przez wagę w celu identyfikacji tylko “ważnych” wartości całość przeliczamy jeszcze przez funkcję aktywacyjną. Tak zwana warstwa ReLU usuwa ujemne wartości z mapy aktywacji, ustawiając je na zero, co zwiększa nieliniowe właściwości funkcji decyzyjnej i całej sieci.



$$f(x) = x^+ = \max(0, x)$$

Rysunek 2.3. Funkcja ReLU

Źródło: Opracowanie własne

Dane są często dzielone na osobne zestawy próbek szkoleniowych i próbek walidacyjnych, co pozwala na ocenę modelu na podstawie danych, na których nie był szkolony.

Funkcja strat (ang. loss function) to miara błędu w wykonywaniu zadania, takiego jak błąd między przewidywanymi wyjściami a mierzonymi wartościami. Celem jest, aby funkcja straty była jak najniższa.

Warto dodać iż często w przypadku gdy sieć neuronowa ma rozpoznawać zależności bazujące na kształtach a rozpoznawanie cyfr pisanych właśnie takie jest, często redukuje się dane wejściowe do minimum. Zamienia się wtedy kolorowy obrazek RGB na czarno-biały. Dzięki takiemu zabiegowi sieć

neuronowa nie jest zaśmiecona niepotrzebnymi danymi jakim jest kolor i może to dać lepszą rozpoznawalność jak również wzrost wydajności zarówno w procesie szkolenia jak i działania klasyfikatora.

Uczenie się jest oszacowaniem parametrów.

Podsumowując można uważać za poprawne stwierdzenie, iż uczenie się sieci to tylko modyfikowanie wag oraz odchyleń tak, aby osiągać najlepsze rezultaty.

ROZDZIAŁ 3

Widzenie komputerowe

Wprowadzenie konwolucyjnych sieci neuronowych zrewolucjonizowało wizję komputerową, a systemy oparte na obrazach zyskały nowy zestaw możliwości. Model teoretyczny musiał spotkać się z implementacją, która skorzysta z dobrodziejstw uczenia maszynowego.

Po załadowaniu jednego z popularnych formatów obrazów, a należy przekształcić dane w reprezentację tensora, która ma różne części obrazu ułożone w sposób zgodny z oczekiwaniami danego API uczenia maszynowego.


Tensor, jest to wielowymiarowa tablica, są elementami składowymi danych w PyTorch. Sieci neuronowe pobierają tensory na wejściu i wytwarzają tensory jako wyjścia. W rzeczywistości wszystkie operacje w sieci neuronowej i podczas optymalizacji są operacjami między tensorami, a wszystkie parametry (takie jak wagi i odchylenia) w sieci neuronowej są tensorami.

Termin tensor jest dołączony do pojęcia przestrzeni, układów odniesienia i transformacji między nimi. Dla wszystkich innych tensor odnosi się do uogólnienia wektorów i macierzy do dowolnej liczby wymiarów, jak pokazano na rysunku. Tensor reprezentujące wartości w poszczególnych pikselach są często kodowane za pomocą liczb 8-bitowych, na przykład w kamerach konsumenckich. W zastosowaniach medycznych, naukowych i przemysłowych nierzadko można znaleźć piksele o większej precyzji numerycznej, takie jak 12-bitowe i 16-bitowe.

Ta precyzja zapewnia szerszy zakres lub zwiększoną czułość w przypadkach, w których piksel koduje informacje dotyczące właściwości fizycznej, takiej jak gęstość kości, temperatura lub głębokość.

Istnieje kilka sposobów kodowania liczb na kolory. Najczęstszym jest RGB, która określa kolor za pomocą trzech liczb reprezentujących intensywność czerwieni, zieleni i niebieskiego.

W tym momencie obrazek jest obiektem podobnym do tablicy o trzech



Rysunek 3.1. Schemat przetwarzania obrazu

Źródło: Opracowanie własne

wymiarach: dwóch wymiarach przestrzennych (szerokość i wysokość) i trzecim wymiarze odpowiadającym kanałom czerwonym, zielonym i niebieskim.

Każdy kolor będzie reprezentowany jako 8-bitowa liczba całkowita, jak w większości formatów fotograficznych ze standardowych aparatów konsumenckich.

Sieci neuronowe zwykle działają z wejściowymi tensorami zmiennoprzecinkowymi. Sieci neuronowe wykazują najlepszą wydajność treningu, gdy dane wejściowe mieszczą się w przedziale od około 0 do 1 lub -1 do 1 (efekt definiowania ich bloków konstrukcyjnych). Sieci neuronowe wymagają przed-

stawienia danych jako wielowymiarowych tensorów numerycznych, często 32-bitowych liczb zmiennoprzecinkowych.

Typową rzeczą, którą należy zrobić, jest rzutowanie tensora na zmiennoprzecinkowe i normalizacja wartości pikseli. Rzutowanie na zmiennoprzecinkowe jest łatwe, ale normalizacja jest trudniejsza, ponieważ zależy od tego, jaki zakres danych wejściowych, który zdecydujesz, powinien wynosić od 0 do 1 (lub -1 do 1). Jedną z możliwości jest podzielenie wartości pikseli przez 255 (maksymalna reprezentowana liczba w 8-bitowym znaku bez znaku):

Na tensorach można wykonać kilka innych operacji na danych wejściowych, w tym przekształcenia geometryczne, takie jak obrót, skalowanie i kadrowanie. Operacje te mogą pomóc w szkoleniu lub mogą być wymagane, aby dowolne dane wejściowe były zgodne z wymaganiami wejściowymi sieci, takimi jak rozmiar obrazu. Natkniesz się na kilka z tych strategii. Na razie pamiętaj tylko, że masz dostępne opcje manipulacji obrazem.

ROZDZIAŁ 4

Transfer Stylu

Neural-Style opracowany przez Leona A. Gatysa, Alexandra S. Eckera i Matthiasa Bethge. Neural-Style lub Neural-Transfer pozwala robić zdjęcia i odtwarzać je w nowym stylu artystycznym. Algorytm pobiera trzy obrazy, obraz wejściowy, obraz treści i obraz stylu, i zmienia dane wejściowe, aby przypominały treść obrazu treści i styl artystyczny obrazu stylu.

W przykładzie, w którym algorytm rozpoznawał cyfry neuronem był pojedynczy piksel ze skalą szarości (grayscale), w przypadku Style Transferu mamy dwa obrazki o pełnym spektrum RGB (red, green, blue), także neuron będzie bardziej skomplikowany. Ostatnią warstwą jest output są pixele w tej samej ilości i układzie, ale ze zmienionymi wartościami.



Rysunek 4.1. Przykład zastosowania tranferu stylu

Źródło: Opracowanie własne

ROZDZIAŁ 5

Przegląd dostępnych narzędzi

5.1. Blender

Jest to wolne i otwarte oprogramowanie do modelowania i renderowania obrazów oraz animacji trójwymiarowych.

Pozwala on na pisanie w języku python skryptów, które poszerzają podstawowe funkcjonalności blendera.

5.2. Python

Język powstały w latach dziewięćdziesiątych, między innymi dzięki rewolucji uczenia maszynowego przeżywa swoją drugą młodość.

Cechuje się klarownością kody źródłowego. Jest to język z którego w większości składa się Blender.

Każda wersja blendera ma wbudowaną już własną wersję pythona.

5.3. Wtyczki

Jedną z wielu zalet środowiska Blender jest jego otwartość. Większość kodu jest otwarta i konfigurowalna, ułatwia to tworzenie rozszerzeń (wtyczek).

Wtyczki w Blenderze mogą istnieć w postaci pojedynczych skryptów *.py* lub zestawu skryptów pakowanych w *.zip*. Uruchamiany wtedy jest plik *init.py*

Zarówno wtyczki do Blendera jak i same operacje przy użyciu PyTorch'a mogą być tworzone na dowolnym systemie operacyjnym. Te narzędzia znacznie ułatwiają pracę nad tego typu oprogramowaniem.

5.4. PyCharm

Zintegrowane środowisko programistyczne (IDE) dla języka programowania Python firmy JetBrains. Zapewnia m.in.: edycję i analizę kodu źródłowego, graficzny debugger, uruchamianie testów jednostkowych, integrację z systemem kontroli wersji.

5.5. Jupyter Notebook

Interaktywne środowisko pozwalające na wykonywanie kodu uczenia maszynowego po stronie serwera. Pozwala na szybkie debugowanie i testowanie kodu między innymi biblioteki PyTorch.

5.6. CUDA

(ang. Compute Unified Device Architecture) – opracowana przez firmę Nvidia uniwersalna architektura procesorów wielordzeniowych (głównie kart graficznych) umożliwiająca wykorzystanie ich mocy obliczeniowej do rozwiązywania ogólnych problemów numerycznych w sposób wydajniejszy niż w tradycyjnych, sekwencyjnych procesorach ogólnego zastosowania.

FLOPS (od ang. floating point operations per second) operacje zmiennoprzecinkowe na sekundę) – jednostka mocy obliczeniowej komputerów, używana szczególnie w zastosowaniach naukowych. Jest bardziej uniwersalna od wcześniej używanej jednostki MIPS, oznaczającej liczbę rozkazów procesora wykonanych na sekundę.

ROZDZIAŁ 6

Przegląd dostępnych bibliotek

6.1. PIP

Standardowy system zarządzania rozszerzeniami i bibliotekami w Pythonie.

6.2. BPY

To biblioteka do komunikowania się z Blenderem.

6.3. PyTorch

PyTorch to biblioteka programów w języku Python, która ułatwia budowanie projektów głębokiego uczenia się. Podkreśla elastyczność i pozwala wyrazić modele głębokiego uczenia się w idiomatycznym języku Python. Ta przystępność i łatwość użycia znalazły wczesnych użytkowników w społeczności badawczej, a od lat od wydania biblioteki stała się jednym z najważniejszych narzędzi do głębokiego uczenia się dla szerokiego zakresu aplikacji.

```
python.exe -m pip install torch
```

Od czasu wydania PyTorch na początku 2017 r. Ekosystem narzędzi do głębokiego uczenia się został znacznie ujednolicony. Dzięki interakcjom bibliotek PyTorch ze standardową biblioteką Python i otaczającym ekosystemem, ładowanie najpopularniejszych rodzajów danych i konwertowanie ich do tensorów PyTorch jest wygodne. Tensory to podstawowe struktury danych w PyTorch. Tensor to tablica - to znaczy struktura danych przechowująca zbiór liczb, które są dostępne indywidualnie za pomocą indeksu i które mogą być indeksowane za pomocą wielu indeksów.

Biblioteki takie jak PyTorch pozwalają efektywnie budować i trenować modele sieci neuronowych.

PyTorch zapewnia podstawową strukturę danych, Tensor, wielowymiarową tablicę, która ma wiele podobieństw z tablicami NumPy. Na tej podstawie opracowano listę rzeczy do prania, aby ułatwić uruchomienie projektu lub zaprojektowanie i przeszkolenie w zakresie nowej architektury sieci neuronowej. Tensory przyspieszają operacje matematyczne (przy założeniu, że obecna jest odpowiednia kombinacja sprzętu i oprogramowania), a PyTorch ma pakiety do rozproszonego szkolenia, procesy robocze dla efektywnego ładowania danych oraz obszerną bibliotekę wspólnych funkcji głębokiego uczenia.

PyTorch stanowi zarówno doskonałe wprowadzenie do głębokiego uczenia się, jak i narzędzie przydatne w profesjonalnych kontekstach do pracy na wysokim poziomie w świecie rzeczywistym.

Po pierwsze, PyTorch ma Py z Pythona, ale jest w nim dużo kodu innego niż Python. Ze względu na wydajność większość PyTorch jest napisana w C++ i CUDA, języku podobnym do C++ od NVIDIA, który można skompilować tak, aby działał z ogromną równoległością na procesorach graficznych NVIDIA. Istnieją sposoby uruchamiania PyTorch bezpośrednio z C.

U podstaw PyTorch jest biblioteka, która udostępnia tablice wielowymiarowe, zwane tensorami w języku PyTorch, a moduł palnika zapewnia obszerną bibliotekę operacji na nich. Zarówno tensory, jak i powiązane operacje mogą działać na CPU lub GPU.

Uruchomienie na GPU powoduje ogromne przyspieszenie w porównaniu z procesorem (szczególnie jeśli jesteś gotów zapłacić za GPU najwyższej klasy), a dzięki PyTorch nie wymaga więcej niż dwóch dodatkowych wywołań funkcji. Druga podstawowa rzecz, którą zapewnia PyTorch, pozwala tensorom śledzić wykonywane na nich operacje i obliczać pochodne wyjścia w odniesieniu do dowolnego z jego danych wejściowych w sposób analityczny poprzez propagację wsteczną.

PyTorch może być wykorzystywany do fizyki, renderowania, optymalizacji, symulacji, modelowania i tak dalej. PyTorch jest wykorzystywany w kreatywny sposób w całym spektrum zastosowań naukowych. Modele głębokiego

bokiego uczenia automatycznie uczą się kojarzyć dane wejściowe i pożądane wyniki z przykładów.

Aby trenować model, potrzeba: źródła danych treningowych, optymalizatora do dostosowania modelu do danych treningowych pętli sposobu uzyskania modelu i danych sprzętu, które będą wykonywać obliczenia potrzebne do wyszkolenia modelu.

W najprostszym przypadku model wykona wymagane obliczenia na lokalnym procesorze lub na pojedynczym GPU, więc gdy pętla treningowa zawiera dane, obliczenia mogą rozpocząć się natychmiast. Częściej jednak trzeba korzystać ze specjalistycznego sprzętu, takiego jak wiele procesorów graficznych lub aby wiele maszyn włączyło swoje zasoby w szkolenie modelu.

```
torch.cuda.is_available()
```

Gdy uzyskasz wyniki z uruchomienia modelu na danych treningowych, `torch.optim` zapewnia standardowe sposoby aktualizacji modelu, dzięki czemu dane wyjściowe zaczną bardziej przypominać odpowiedzi określone w danych treningowych. PyTorch domyślnie przyjmuje model natychmiastowego wykonania (tryb eager). Ilekroć instrukcja dotycząca PyTorch jest wykonywana przez interpreter Pythona, odpowiednia operacja jest natychmiast wykonywana przez bazową implementację C++ lub CUDA. Ponieważ więcej instrukcji działa na tensorach, więcej operacji jest wykonywanych przez implementację backendu. Proces ten jest tak szybki, jak zwykle może być po stronie C++, ale wiąże się z kosztami wywołania tej implementacji za pośrednictwem Pythona. Koszt ten jest niewielki, ale sumuje się. Odroczone wykonanie Nie wykonałeś niczego, dopóki nie podałeś danych wejściowych. Odroczenie wykonania oznacza, że większość wyjątków powstaje, gdy funkcja jest wywoływana, a nie kiedy jest zdefiniowana. W przypadku normalnego Pythona (jak widać tutaj) nie ma problemu, ponieważ interpreter i debugery mają pełny dostęp do stanu Python w momencie wystąpienia błędu. Sprawy stają się trudne, gdy stosuje się wyspecjalizowane klasy z dużym przeciążeniem operatora, co pozwala na odroczenie tego, co wygląda jak natychmiastowe wykonanie pod maską. Ładowanie Tensora do GPU Oprócz dtype, tensor PyTorch ma pojęcie urządzenia, czyli miejsca, w którym na

komputerze umieszczane są dane tensora. Oto jak utworzyć tensor na GPU, podając odpowiedni konstruktor:

```
points_gpu = torch.tensor([[2.1, 3.7], [4.2, 0.0], [6.9, 6.9]], device='cuda')
```

Kopiowanie tensora utworzonego w CPU do GPU: *points_gpu = points.to(device='cuda')*

Ten kod zwraca nowy tensor, który ma te same dane liczbowe, ale jest przechowywany w pamięci RAM GPU, a nie w zwykłej pamięci RAM systemu

Tensor, którego wartości są określone w pamięci, zaczynając od skrajnego wymiaru po prawej stronie (na przykład wzdłuż rzędów dla tensora 2D) jest definiowany jako ciągły. Przyległe tensory są wygodne, ponieważ można je odwiedzać sprawnie i po kolei bez skakania po magazynie. (Poprawa lokalizacji danych poprawia wydajność ze względu na sposób dostępu do pamięci w nowoczesnych procesorach).

Te reprezentacje zmiennoprzecinkowe są przechowywane w tensorach. Tensory to tablice wielowymiarowe i podstawowa struktura danych w PyTorch. PyTorch ma wszechstronną bibliotekę standardową do tworzenia tensorów i manipulacji laton i do operacji matematycznych. Tensory można uszeregować na dysk i ładować z powrotem. Wszystkie operacje tensora w PyTorch mogą być wykonywane zarówno na CPU, jak i na GPU bez zmiany kodu.

Interpreter języka Python działa wolno w porównaniu ze zoptymalizowanym, skomplikowanym kodem. Wykonywanie operacji matematycznych na dużych kolekcjach danych liczbowych może być szybsze przy użyciu zoptymalizowanego kodu napisanego w skompilowanym języku niskiego poziomu, takim jak C.

6.4. NumPy

NumPy jest zdecydowanie najpopularniejszą biblioteką wielowymiarową. PyTorch oferuje płynną interoperacyjność z NumPy, co zapewnia pierwszorzę-

ną integrację z resztą bibliotek naukowych w języku Python, takie jak SciPy, Scikit-learn i Pandas.

W porównaniu z macierzami NumPy, tensory PyTorch mają kilka supermocarstw, takich jak zdolność do wykonywania szybkich operacji na graficznych jednostkach przetwarzających (GPU), do dystrybucji operacji na wielu urządzeniach lub maszynach oraz do śledzenia wykresu utworzonych obliczeń im. Wszystkie te funkcje są ważne przy wdrażaniu nowoczesnej biblioteki do głębokiego uczenia się.

Tensory PyTorch można konwertować na tablice NumPy i odwrotnie. W ten sposób można wykorzystać ogromną liczbę funkcji w szerszym ekosystemie Pythona, który zbudował się wokół typu tablicy NumPy. Ta zerowa kopia współdziałania z tablicami NumPy wynika z systemu pamięci, który współpracuje z protokołem buforującym Pythona. Ze względu na jego wszechobecność w ekosystemie nauki danych w Pythonie łatwa zamiana tensora na tablicę NumPy, aby użyć charakterystycznych dla NumPy metod bywa przydatne.

6.5. Torchvision

Torchvision składa się z popularnych zestawów danych, architektur modeli i typowych transformacji obrazu. Torchvision udostępnia wiele wytrenowanych wcześniej modeli, które są gotowe do użycia. Skupmy się na jednym, mianowicie VGG19 (ang. Visual Geometry Group) to wytrenowana na Uniwersytecie Oxfordzkim konwolucyjna sieć neuronowa.

```
models.vgg19(pretrained=True).features
```

6.6. Pillow

(ang. Python Image Library PIL) dodaje obsługę grafiki np. otwieranie, modyfikowanie, zapisywanie plików graficznych.

6.7. OS

Biblioteka implementująca interfejsy systemu operacyjnego. W przypadku tej pracy pozwala wykonać instalację paczek w tle poprzez wykonanie procesu terminalowego w tle.

```
os.popen(cmd)
```

ROZDZIAŁ 7

Źródła

- Vishnu Subramanian Deep Learning with PyTorch
- Grokking Deep Learning, by Andrew W. Trask
- Deep Learning with PyTorch by Eli Stevens and Luca Antiga
- Czysty kod. Podręcznik dobrego programisty Robert C. Martin
- [https : //pytorch.org/tutorials/advanced/neural_style_tutorial.html](https://pytorch.org/tutorials/advanced/neural_style_tutorial.html)
- [https : //github.com/rrmina/neural - style - pytorch](https://github.com/rrmina/neural-style-pytorch)
- [https : //polycount.com/discussion/205872/creating-images-with-python - in - blender](https://polycount.com/discussion/205872/creating-images-with-python-in-blender)
- [https : //cloud.blender.org/p/scripting-for-artists/5993ed908119170ebb57164b](https://cloud.blender.org/p/scripting-for-artists/5993ed908119170ebb57164b)
- [https : //www.3blue1brown.com](https://www.3blue1brown.com)
- [https : //www.manning.com/books/grokking - deep - learning](https://www.manning.com/books/grokking-deep-learning)
- [https : //www.deeplearningbook.org](https://www.deeplearningbook.org)
- *Deep Learning, by Ian Goodfellow, Yoshua Bengio, and Aaron Courville.*

Zakończenie

Możliwości jaki stoją przed obrazami generowanymi maszynowo są nieograniczone zarówno do prototypowania i tworzenia "bazy" pomysłów, jak również do odciążania człowieka z zadań które jeszcze kilka lat temu były wykonalne tylko dla najlepszych specjalistów w branży.

DODATEK A

Tytuł załącznika jeden

Treść załącznika jeden.

DODATEK B

Tytuł załącznika dwa

Treść załącznika dwa.

Oświadczenie

Ja, niżej podpisany(a) oświadczam, iż przedłożona praca dyplomowa została wykonana przeze mnie samodzielnie, nie narusza praw autorskich, interesów prawnych i materialnych innych osób.

.....

data

.....

podpis